

Aisthesis: Un'Architettura Ibrida per la Classificazione Emozionale e la Mappatura Sinestetica in Tempo Reale

Alessio Pecilli¹ and Matteo Cerretani¹

¹Ingegneria Informatica, Laurea Magistrale, Università degli Studi Roma Tre, Roma, Italia

Sommario

La classificazione automatica delle emozioni testuali e la loro traduzione in stimoli multisensoriali rappresentano sfide aperte nell'interazione uomo-macchina (HCI). Questo lavoro presenta *Aisthesis*, un framework interattivo in tempo reale che propone una strategia ibrida per **mitigare alcune limitazioni** delle architetture NLP pre-addestrate a ontologia chiusa. Il sistema fonde FEEL-IT (UmBERTo fine-tuned, 4 emozioni primarie) con un lessico cromatico goethiano a 11 colori (7 canonici + 4 estensioni documentate). Le emozioni sono proiettate nel Modello Circompleso di Russell (ausiliario); i colori nello spazio HSV; a valle, il *blend* cromatico pilota una sintesi sonora deterministica (Web Audio API). Un modulo XAI basato su Integrated Gradients e allineamento lessicale rende espliciti i conflitti tra canale neurale e simbolico. Uno **studio esplorativo preliminare** su un corpus di controllo di 44 frasi italiane (costruito dagli autori) indica che l'ibrido con *boost* lessicale porta l'accuratezza cromatica dal 31,8% (solo FEEL-IT) all'81,8%, con recupero completo (100%) su etichette affettive isolate nel corpus considerato.

Parole chiave: Classificazione Emozionale; Architettura Ibrida; Reti Transformer; Psicoacustica; Teoria dei Colori di Goethe; Explainable AI; Sintesi Generativa; Affective Computing.

1 Introduzione

Negli ultimi due decenni, l'Affective Computing ha trasformato il modo in cui i sistemi informativi comprendono e processano il linguaggio umano. L'estrazione di metriche emozionali dal testo, storicamente affidata a rudimentali tecniche di sentiment analysis basate su dizionari a polarità binaria (positivo/negativo), ha compiuto un balzo in avanti con l'avvento dei modelli linguistici profondi (Deep Learning) basati sull'architettura Transformer [4]. Tuttavia, la mera estrazione dell'etichetta emozionale (es. "gioia", "rabbia") restituisce un'informazione ridotta rispetto alla ricchezza dell'esperienza affettiva che un sistema sinestetico dovrebbe evocare.

Parallelamente, il concetto di *sinestesia computazionale*, ovvero la traduzione algoritmica di uno stimolo da una modalità sensoriale a un'altra in modo consistente e predicibile, sta guadagnando trazione nel campo delle interfacce utente avanzate e dell'arte generativa. La sfida principale risiede nella definizione delle regole di mappatura (*mapping rules*): tradurre la semantica astratta del linguaggio in frequenze visive e uditive richiede un substrato teorico rigoroso per evitare che l'output risulti caotico o psicologicamente dissonante.

Il progetto *Aisthesis* nasce per colmare questa distanza, proponendo un'infrastruttura capace di tradurre il linguaggio naturale in un paesaggio sonoro e cromatico in tempo reale. Per farlo in modo

semanticamente fondato, *Aisthesis* implementa una rilettura computazionale della *Teoria dei Colori* (Zur Farbenlehre, 1810) di Johann Wolfgang von Goethe [2], incrociandola con il modello spaziale delle emozioni di Russell [3].

Questo documento descrive le scelte architettoniche, i modelli matematici e la strategia ibrida impiegate per mantenere latenze compatibili con l'uso interattivo, pur offrendo output estetici strutturati e spiegazioni tracciabili sui canali neurale e simbolico.

Terminologia. Nel testo si usano in modo uniforme: **blend** (miscela pesata di colori); **top- k** (i k colori con peso maggiore dopo fusione); **boost lessicale** (incremento di β su frasi brevi); **contraddizione** (disaccordo tra top-1 neurale e top-1 lessicale); **traccia esplicativa** (*rule trace*, log testuale delle regole applicate).

2 Related Work

2.1 Teoria dei colori e estetica goethiana

La *Farbenlehre* di Goethe (1810) non descrive solo la fisica ottica, ma soprattutto l'**effetto sensibile-morale** (*sinnlich-sittliche Wirkung*) dei colori: il giallo come sereno e lieto, il blu come distante e malinconico, il vermiglio come polo attivo della passione. *Aisthesis* usa esplicitamente questa ontologia, distinguendo colori canonici e quattro estensioni motivate da letteratura empirica su emozione-colore [6]. A differenza di approcci puramente derivati da sentiment analysis generica, il mapping è **interpretativo**: ogni colore porta citazione, polo attivo/passivo e profilo sonoro coerente con il carattere goethiano.

2.2 Emozione-colore e corrispondenze cross-modalità

Palmer et al. [6] mostrano associazioni sistematiche tra emozioni e colori in contesti culturali occidentali. Marks [7] formalizza le *cross-modal correspondences*: luminosità $\leftrightarrow$ altezza del pitch, saturazione $\leftrightarrow$ timbro. Ferguson e Brewster [8] collegano *sharpness* e arousal a timbri penetranti. *Aisthesis* traduce queste corrispondenze in parametri sonori per colore (scala, attacco, riverbero, filtro), fusi poi sul blend cromatico. Il suono è **co-determinato** dal colore goethiano dominante.

2.3 Classificazione emotiva neurale in italiano

FEEL-IT [1] è un encoder UmBERTo (RoBERTa italiano) fine-tuned su tweet italiani con quattro classi: gioia, rabbia, tristezza, paura. Presenta limiti su input minimali e su emozioni fuori dal training set (amore, disgusto, fiducia). Il contributo di *Aisthesis* è l'**ibrido goethiano**: FEEL-IT fornisce contesto distribuzionale; GOETHE_LEXICON ancora parole italiane a colori con tracciabilità; la fusione pesata con *short-text boost* mitiga gli errori del modello su etichette isolate, come quantificato in Sezione 8.

2.4 Sistemi affettivi multimodali e XAI

Sistemi testo→immagine o testo→musica basati su modelli generativi offrono varietà ma scarsa tracciabilità. *Aisthesis* privilegia determinismo e spiegabilità esplicita: Integrated Gradients [5] sul canale neurale, allineamento lessicale e traccia esplicativa (*rule trace*) sul canale simbolico.

3 Fondamenti Teorici

3.1 Modelli Ontologici delle Emozioni

La classificazione delle emozioni nell'Intelligenza Artificiale si divide tradizionalmente in approcci categoriali e approcci dimensionali. L'approccio categoriale, derivato dagli studi di Paul Ekman e Robert Plutchik, postula l'esistenza di un numero finito di stati emotivi discreti. Le reti neurali moderne (come il modello FEEL-IT [1] utilizzato in questo progetto) sono spesso addestrate su corpora etichettati secondo i 4 stati primari universalmente riconosciuti: Gioia, Tristezza, Rabbia e Paura. Tuttavia, tale limitazione restringe severamente l'espressività di un sistema sinestetico, ignorando sfumature vitali quali la sorpresa, il disgusto o l'amore.

Per contro, l'approccio dimensionale descrive le emozioni come punti in uno spazio vettoriale continuo. Il Modello Circomplesso di James Russell [3] mappa gli stati affettivi su due assi ortogonali:

- **Valenza (Valence):** Asse $X \in [-1, 1]$, misura il grado di piacevolezza o sgradevolezza (da negativo a positivo).
- **Attivazione (Arousal):** Asse $Y \in [-1, 1]$, misura il livello di attivazione fisiologica e psicologica (da letargico a iper-attivo).

In *Aisthesis*, l'approccio dimensionale è **ausiliario**: le emozioni dell'ontologia espansa (ibrido neurale + lessico) vengono aggregate in un vettore **a** e proiettate nello spazio di Russell tramite coordinate fisse per emozione (Sezione 4.4). Il risultato alimenta la visualizzazione affettiva e la *rule trace*, mentre output cromatico e sonoro dipendono dal blend goethiano.




Figura 1: Il Modello Circomplesso delle Emozioni di Russell: stati affettivi su assi di Valenza e Attivazione.

3.2 La Teoria dei Colori di Goethe in Contesto Computazionale

Contrariamente all'ottica newtoniana, che analizza il colore come un fenomeno puramente fisico legato alla scomposizione spettrale, Goethe propone un approccio olistico e fenomenologico. Egli postula che il colore nasca dal conflitto percettivo tra la luce (*Licht*) e l'oscurità (*Finsternis*).

Dal punto di vista dell'Affective Computing, la validità dell'opera di Goethe risiede nella sua sezione dedicata all'azione "sensibile-morale" (*sinnlich-sittliche Wirkung*) dei colori. Goethe divide la ruota cromatica in poli psicologici:

- **Polo Attivo (Plus):** Comprende Giallo, Arancione e Vermiglio. Questi colori eccitano, riscaldano e spingono all'azione. Correlano positivamente con alte Valenze e alti Arousal.
- **Polo Passivo (Minus):** Comprende Blu e Violetto. Generano inquietudine, senso di vuoto e freddo. Correlano con basse Valenze.
- **Punti di Equilibrio:** Il Verde emerge come pacificazione sensoriale tra Giallo e Blu, mentre il Porpora rappresenta l'esaltazione massima (Awe/Ammirazione).




Figura 2: La ruota dei colori fenomenologica teorizzata da J.W. von Goethe.

4 Architettura di Aisthesis

L'infrastruttura di Aisthesis è concepita secondo il paradigma client-server (dettaglio tecnologico in Sezione 5): backend asincrono in Python con FastAPI [9], frontend in JavaScript vanilla con Web Audio API. Il codice sorgente è pubblico nel repository indicato in bibliografia [10].

4.1 Architettura end-to-end




Figura 3: Architettura di Aisthesis v5. I due canali convergono nella fusione pesata; il blend alimenta output visivo, sonoro e spiegabilità.

4.2 Il Motore NLP Ibrido: Rete Neurale e Lexical Override

Il cuore semantico neurale di Aisthesis poggia su `MilaNLPProc/feel-it-italian-emotion`, un riferimento consolidato per la classificazione emotiva in italiano [1]. Sotto il cofano, esso sfrutta UmBERTo (RoBERTa italiano), pre-addestrato su corpora di testo italiano e sottoposto a *fine-tuning* sul dataset FEEL-IT. L'ultimo livello denso esegue una classificazione softmax sulle 4 classi primarie: $P_{\text{neural}} = \{p_{\text{joy}}, p_{\text{sadness}}, p_{\text{anger}}, p_{\text{fear}}\}$.

Su frasi con contesto sintattico adeguato il modello offre buone prestazioni; su input minimali presenta però bias legati ai dati di addestramento. Nei test interni, termini privi di contesto ma fortemente positivi come “fortunato” hanno provocato picchi impropri nella classe Paura ($p_{\text{fear}} \approx 0,70$).

Inoltre, la necessità di mappare 11 colori (e non 4) ha reso imperativa l'espansione dell'ontologia. È stato quindi sviluppato un **Motore Lessicale Ibrido**.

Notazione. Sia t il testo in input; $\mathcal{E}$ l'insieme delle emozioni FEEL-IT (4 classi) e $\mathcal{E}^+$ l'ontologia espansa (11 emozioni); $\mathcal{C}$ l'insieme dei 11 colori Goethe ($|\mathcal{C}|=11$). Si indicano con $\mathbf{p}^{\text{model}}$ le probabilità softmax di FEEL-IT, con $\phi: \mathcal{E}^+ \rightarrow \mathcal{C}$ la mappa emozione→colore (EMOTION_TO_GOETHE), con $\mathbf{m}, \ell \in \mathbb{R}^{|\mathcal{C}|}$ rispettivamente le distribuzioni sul canale neurale e lessicale (normalizzate, $\sum_c m_c = \sum_c \ell_c = 1$ quando definite), con α, β i pesi di fusione ($\alpha+\beta=1$), con n il numero di parole in t (token alfanumerici estratti con regex su parole italiane), e con $\tilde{\mathbf{w}}$ il blend finale dopo top- k e smoothing.

La pipeline cromatica esegue due canali paralleli:

1. **Canale neurale:** FEEL-IT restituisce $\mathbf{p}^{\text{model}}$ sulle 4 emozioni; si aggrega e si traduce in colori con $m_c = \sum_{e: \phi(e)=c} p_e^{\text{model}}$ (normalizzato su $\mathcal{C}$).
2. **Canale lessicale:** ogni occorrenza di una keyword w mappata al colore c in GOETHE_LEXICON contribuisce con peso grezzo $s_c(w, i)$ (Sezione sotto).

4.2.1 Peso lessicale grezzo e negazione

Per ogni keyword w del lessico si cercano tutte le occorrenze in t (match esatto su sottostringa, case-insensitive). Per ciascuna occorrenza in posizione i :

$$s_c(w, i) = \begin{cases} 0,25 & \text{se } w \text{ è negata nei 30 caratteri precedenti a } i \\ 1,00 & \text{altrimenti} \end{cases} \quad (1)$$

con negatori $\{non, mai, senza, niente, né, ne\}$. Il punteggio grezzo del colore c è $S_c = \sum_{w \in \text{Lex}(c)} \sum_{i \in \text{Occ}(w, t)} s_c(w, i)$ dove $\text{Lex}(c)$ sono le keyword di c e $\text{Occ}(w, t)$ le posizioni di w in t . Se $\sum_{c'} S_{c'} > 0$, la distribuzione lessicale è

$$\ell_c = \frac{S_c}{\sum_{c'} S_{c'}}; \quad (2)$$

altrimenti $\ell = \mathbf{0}$. In assenza di match lessicali ($\ell = \mathbf{0}$), la pipeline demanda la decisione esclusivamente al canale neurale. La negazione *attenua* il peso grezzo (da 1,00 a 0,25) ma, se una sola parola è attivata, la normalizzazione può comunque produrre $\ell_c = 1$ su quel colore: è un limite noto del modulo simbolico, discusso in Sezione 8.6.

4.2.2 Fusione ibrida e Boost su frasi corte

Siano $\mathbf{m}$ e ℓ le distribuzioni sui colori. Pesi di default: $\alpha = 0,5$ (modello), $\beta = 0,5$ (lessico). Sia n il numero di token alfabetici in t e $\ell^* = \max_c \ell_c$. Se $n \leq 6$ e $\ell^* \geq 0,4$, si imposta $\beta = 0,72$, $\alpha = 0,28$ (**Boost lessicale**).

$$h_c = \alpha m_c + \beta \ell_c, \quad \hat{h}_c = \frac{h_c}{\sum_{c'} h_{c'}}. \quad (3)$$

4.2.3 Smoothing del blend (top- k)

Sia $\hat{\mathbf{h}}$ la distribuzione normalizzata della fusione. Si ordinano i colori per $\hat{h}_c$ decrescente, si selezionano i primi $k \leq 4$ e si ponga $h^* = \max_c \hat{h}_c$. Si applica l'esponente

$$p = \begin{cases} 1,0 & \text{se } h^* > 0,75 \quad (\text{dominanza forte}) \\ 0,65 & \text{altrimenti} \quad (\text{mix pi\`u equilibrato}) \end{cases} \quad (4)$$

sui soli colori selezionati: $\bar{h}_c = \hat{h}_c^p$. Si scartano i colori con $\bar{h}_c / \sum_{c'} \bar{h}_{c'} < 0,05$ e si rinormalizza per ottenere i pesi finali $\tilde{w}_c$ ($\sum_c \tilde{w}_c = 1$). L'esponente $p < 1$ attenua la dominanza di un singolo colore; il cut-off a 0,05 riduce il rumore residuale del modello.

4.3 Calibrazione degli iperparametri

I parametri della pipeline (Tab. 1) sono stati **calibrati empiricamente** sul corpus di controllo di $N=44$ stimoli (Sezione 8). Poich\'e calibrazione e valutazione avvengono sullo stesso insieme, i risultati vanno interpretati come **preliminari**: esiste rischio di *overfitting* su esempi noti. In sviluppi futuri sar\'a necessario separare un insieme di sviluppo da un test set indipendente, con annotazioni prodotte da pi\`u valutatori.

Tabella 1: Iperparametri calibrati e motivazione

Parametro	Valore	Criterio di ottimizzazione
Peso modello α (default)	0,50	Equilibrio su frasi lunghe
Peso lessico β (default)	0,50	Complementare ad α
Boost lessico (frasi corte)	0,72	Max acc. su $n \leq 6$ token
Soglia lunghezza breve	6 token	Punto di knee FEEL-IT vs lessico
Soglia picco lessicale	0,40	Evita boost su match deboli
Top- k blend	4	Compromesso palette / leggibilit\'a
Potenza smoothing	0,65 / 1,0	Mix vs dominanza ($h^* > 0,75$)
Peso minimo blend	0,05	Filtra rumore residuale
Finestra negazione	30 caratteri	Copertura sintassi IT breve
Peso negato	0,25	Attenua senza invertire colore

4.4 Proiezione nello Spazio di Russell (ausiliario)

Parallelamente al blend cromatico, la pipeline costruisce una distribuzione emotiva ibrida $\mathbf{a}$ sulle emozioni di $\mathcal{E}^+$, con gli stessi coefficienti α, β usati per la fusione (il canale lessicale emotivo deriva dal lessico cromatico tramite `color_scores_to_emotions`). Le coordinate affettive sono il centroide

pesato

$$V_{\text{text}} = \sum_{e \in \mathcal{E}^+} a_e v_e, \quad A_{\text{text}} = \sum_{e \in \mathcal{E}^+} a_e a_e^{\text{ar}} \quad (5)$$

con v_e, a_e^{ar} in Tabella 2. Valenza e arousal sono clampati in $[-1, 1]$ e $[0, 1]$ rispettivamente (le coordinate negative di a_e^{ar} , es. fiducia, diventano 0 dopo il clamp). Questo spazio non pilota pitch o BPM, gestiti dai profili sonori per colore, ma descrive il quadrante affettivo in UI e nella *rule trace*.

Tabella 2: Coordinate Russell (EMOTION_VA in `main.py`): valenza v_e e arousal a_e^{ar} prima del clamp.

Emozione	Valenza (v_e)	Arousal (a_e^{ar})	Quadrante tipico
Gioia (<i>joy</i>)	0,82	0,62	I (positivo, attivo)
Amore (<i>love</i>)	0,80	0,30	I
Rabbia (<i>anger</i>)	-0,72	0,88	II (negativo, attivo)
Paura (<i>fear</i>)	-0,65	0,78	II
Tristezza (<i>sadness</i>)	-0,78	0,22	III (negativo, calmo)
Sorpresa (<i>surprise</i>)	0,20	0,85	I
Disgusto (<i>disgust</i>)	-0,60	0,40	II
Fiducia (<i>trust</i>)	0,60	-0,20	IV (positivo, calmo)
Attesa (<i>anticipation</i>)	0,20	0,60	I
Ammirazione (<i>awe</i>)	0,50	0,70	I
Equilibrio (<i>neutral</i>)	0,05	0,30	Centro

5 Stack Tecnologico e Implementazione

Aisthesis v5 è un'applicazione *full-stack* open source [10]. Il repository contiene backend, ontologia cromatica, frontend e script di valutazione riproducibile.

5.1 Backend e inferenza NLP

- **Runtime:** Python 3, server ASGI uvicorn.
- **API:** FastAPI [9] con modelli Pydantic; endpoint principale POST `/process` con corpo `{"text": "..."}.`
- **Classificazione:** PyTorch + Hugging Face `transformers`; modello `MilaNLPProc/feel-it-italian-emotion` (UmBERTo fine-tuned).
- **Ontologia:** modulo `goethe.py`, catalogo 11 colori, lessico `GOETHE_LEXICON`, fusione ibrida, blend HSV, profili `SonicColorProfile`, explainability lessicale.
- **Orchestrazione:** `main.py`, pipeline end-to-end, Integrated Gradients, rule trace, serializzazione JSON della risposta.

5.2 Frontend e sintesi audio

- **UI:** HTML/CSS/JavaScript vanilla (`static/index.html`), senza framework SPA.

- **Audio:** Web Audio API, oscillatori, filtri e riverbero in tempo reale a partire dal profilo sonoro restituito dal backend.
- **Visualizzazione:** layer cromatici HSV, spazio Russell ausiliario, salienza IG e allineamento lessicale.

6 Modello di Mappatura Sinestetica

6.1 Spazio Cromatico HSV: Colori Classici ed Estesi

A ogni emozione dell'ontologia espansa è associato staticamente un colore le cui coordinate giacciono nello spazio HSV (Hue, Saturation, Value). Per preservare il rigore fenomenologico, l'architettura divide esplicitamente la mappatura in due categorie: Colori Classici (Canonici) e Colori Estesi. (Tabella 3):

Tabella 3: Colore, carattere affettivo e citazioni fenomenologiche

Colore	Tipo	HSV	Emozioni	Citazione / Descrizione
Giallo	Canonico	52°, 55%, 95%	gioia	«Il colore più vicino alla luce... sereno, lieto, eccitante.»
Arancione	Canonico	30°, 85%, 95%	calore, entusiasmo	«Un giallo che cresce in densità ed energia...»
Vermiglio	Canonico	8°, 92%, 92%	rabbia	«Il culmine del lato attivo... fuoco e passione.»
Blu	Canonico	225°, 42%, 38%	tristezza	«Il colore più vicino all'oscurità... vuoto e distanza.»
Violetto	Canonico	275°, 55%, 32%	paura	«Più inquieto ed oppressivo» del blu puro.
Porpora	Canonico	290°, 70%, 60%	ammirazione	«Massima dignità... potenza e maestà.»
Verde	Canonico	128°, 38%, 72%	equilibrio	«Unione tra Giallo e Blu in perfetto equilibrio.»
Rosa	Estensione	330°, 35%, 95%	amore	«Riverbero di luce calda... grazia e tenerezza.»
Azzurro	Estensione	195°, 45%, 90%	fiducia	«Vastità e riposo» (Palmer, Marks)
Verde Marcio	Estensione	70°, 60%, 50%	disgusto	«Mescolanza sgradevole» (repulsione)
Cremisi	Estensione	345°, 80%, 75%	attesa, sorpresa	«Oscurarsi verso il rosso... imminenza.»

La somma simultanea di più colori non genera una sovrapposizione opaca. Aisthesis applica una media ponderata circolare su H e medie lineari su saturazione e valore, con pesi $\tilde{w}_c$ e coordinate (H_c, S_c, V_c) del catalogo:

$$\bar{x} = \sum_c \tilde{w}_c \cos(H_c), \quad \bar{y} = \sum_c \tilde{w}_c \sin(H_c), \quad H_{\text{blend}} = \text{atan2}(\bar{y}, \bar{x}) \bmod 360 \quad (6)$$

$$S_{\text{blend}} = \sum_c \tilde{w}_c S_c, \quad V_{\text{blend}} = \sum_c \tilde{w}_c V_c \quad (7)$$

Questa fusione mantiene un colore dominante leggibile pur consentendo sfumature cromatiche nel mix, in linea con l'intento espressivo goethiano.

6.2 Sintesi Sonora Generativa (Web Audio API)

La sonificazione deriva dal **blend cromatico goethiano**, non dalle coordinate Russell (ausiliarie). Ogni colore espone un profilo `SonicColorProfile` (Tab. 4) con scala modale, nota radice MIDI, forma d'onda, BPM, inviluppo ADSR, filtro e riverbero; parametri motivati dalle corrispondenze cross-modalità citate in letteratura [7, 8].

Dati i pesi $\tilde{w}_c$ dopo smoothing top- k , `build_sonic_from_goethe_blend` calcola:

1. **Parametri continui:** pitch radice, BPM, attacco, rilascio, filtro e riverbero come **media pesata** dei profili dei colori nel blend; la radice MIDI è limitata a $[50, 80]$ e convertita in Hz con $f = 440 \cdot 2^{(\text{MIDI}-69)/12}$.
2. **Scala e arpeggio:** dal colore dominante ($\arg \max_c \tilde{w}_c$); intervalli da `SCALE_INTERVALS`, pattern arpeggiato *hardcoded* per colore.
3. **Timbro:** dal profilo dominante, con override verso *sawtooth* se un componente a peso $> 0,2$ lo richiede (es. Verde Marcio), o verso *triangle* se il polo attivo goethiano supera il 50%.
4. **Voices:** fino a quattro oscillatori detuned con ritardi scalati dal bilancio polo attivo/passivo; il frontend li istanzia via Web Audio API senza campioni pre-registrati.

Il fattore di confidenza FEEL-IT modula l'ampiezza ($0,55 + 0,45 \cdot \text{confidence}$), attenuando il segnale su predizioni incerte.

Tabella 4: Profilo sonoro per colore (`SonicColorProfile`)

Colore	Scala	Timbro	MIDI	BPM	Att.	Ril.	Filtro	Rev.	Razionale
Giallo	pent. magg.	sine	67	78	280	1800	2800	0.22	Sereno, medio-alto, morbido
Arancione	misolidia	triangle	69	92	120	1400	3400	0.18	Energia polo attivo, brillante
Vermiglio	frigia	triangle	62	108	45	900	4200	0.12	Fuoco: rapido, scala tesa
Blu	pent. min.	sine	55	62	520	3200	1200	0.62	Grave, lungo riverbero
Violetto	frigia	sine	58	74	180	2600	900	0.48	Filtro chiuso, inquietudine
Porpora	lydian	sine	64	68	400	2800	2200	0.55	Maestosità, ampio respiro
Verde	dorica	sine	60	72	350	2000	2000	0.30	Parametri moderati
Rosa	pent. magg.	sine	66	76	200	2200	2600	0.25	Tenerezza, arpeggio dolce
Azzurro	lydian	sine	68	70	300	2400	3000	0.28	Luminosità, pitch alto
Verde Marcio	frigia	sawtooth	53	58	80	1100	650	0.15	Timbro ruvido, registro basso
Cremisi	misolidia	triangle	63	100	60	1000	3800	0.14	Urgenza, attacco netto

Att. = attacco (ms); Ril. = rilascio (ms); Rev. = mix riverbero.

7 Trasparenza del Modello: Explainable AI

Il sistema incorpora due meccanismi complementari di spiegabilità: Integrated Gradients sul canale neurale e traccia esplicativa (*rule trace*) sul canale simbolico.

7.1 Integrated Gradients (Saliency Map)

L'IG [5] attribuisce a ogni input un contributo alla predizione della classe target. In Aisthesis risponde alla domanda: **quali token hanno spinto FEEL-IT verso un'emozione?**

$$IG_i(x) = (x_i - x'_i) \int_0^1 \frac{\partial F(x' + \lambda(x - x'))}{\partial x_i} d\lambda \quad (8)$$

dove F è il logit della classe target, x l'embedding di input, x' la baseline e $\lambda \in [0, 1]$ il parametro di interpolazione (distinto dai pesi di fusione α, β).

Implementazione (main.py).

- **Baseline x' :** embedding a zero (`torch.zeros_like`), interpolazione lineare fino all'embedding del testo reale.
- **Step di integrazione:** $N=20$ (`IG_STEPS`), con media dei gradienti lungo il percorso.
- **Classe target:** emozione top-1 dell'aggregato ibrido; se `contradiction` è attiva, si spiega l'emozione top del lessico (`lexicon_top_emotion`).
- **Sub-token:** UmBERTo tokenizza in sub-word; i punteggi IG dei token che ricadono nello span di una parola vengono **sommati**, poi normalizzati sul massimo e filtrati ($\geq 0,008$); si mostrano al massimo 6 termini (`EXPLANATION_TOP_TERMS`).
- **Completezza:** l'implementazione segue la formulazione assiomatica di Sundararajan et al. [5]; non è stata verificata numericamente la proprietà di completezza $F(x) - F(x') \approx \sum_i IG_i(x)$ sul classificatore, lasciandone la validazione a studi futuri.

7.2 Tracciamento Deterministico (Rule Trace)

Oltre ai gradienti, il backend genera una *rule trace* in linguaggio naturale. Questo log espone all'utente:

- L'eventuale discrepanza tra modello neurale e lessico, e il motivo della correzione ibrida.
- La genesi della scelta cromatica, riportando i riferimenti teorici associati al colore scelto (citazioni goethiane o fonti delle estensioni documentate).
- Le regole psicoacustiche per colore (Tab. 4) e il bilancio polo attivo/passivo.

Tabella 5: Metriche del modulo di pesatura XAI

Simbolo	Significato	Uso
<code>contradiction</code>	$\phi(e_{\top}^{\text{model}}) \neq \arg \max_c \ell_c$	Disaccordo tra top-1 neurale e lessicale (metrica <i>diagnostica</i> sul corpus)
<code>matched_terms</code>	Parole attivate nel lessico	Trasparenza esplicita
$IG(w)$	Integrated Gradients su FEEL-IT	Salienza neurale (non lessico)

8 Valutazione Preliminare e Ablation Study

8.1 Prestazioni e latenza

Su macchina di sviluppo (CPU x86_64, Windows 11, 16 GiB RAM, inferenza su CPU senza GPU), misurazioni **preliminari** su un campione ridotto di richieste `POST /process` indicano latenza end-to-end (classificazione + IG a 20 step + routing cromatico/sonoro) nell'ordine di **150-280 ms** (media osservata ≈ 210 ms). Non è stata condotta una campagna sistematica con deviazione standard su hardware multipli; i valori vanno intesi come indicativi di fattibilità interattiva, non come benchmark formale. Il routing visivo e sonoro resta a tempo costante $\mathcal{O}(1)$ dopo l'inferenza neurale.

8.2 Studio esplorativo su corpus di controllo

Per integrare esempi qualitativi e metriche aggregate, è stato costruito un **corpus di controllo** di $N=44$ frasi italiane con *gold label* sul colore goethiano atteso (`scripts/eval_corpus.json`). Si tratta di una **valutazione preliminare**, non di una validazione su dataset esterno con annotazione inter-rater. Il corpus copre:

- etichette affettive isolate (*gioia, rabbia...*);
- frasi brevi e lunghe;
- negazione (*non sono felice*);
- casi impliciti con emozione non nominata esplicitamente (*meraviglioso, incredibile*).

Metriche per configurazione.

1. **Accuratezza cromatica:** il colore dominante del blend coincide con il gold;
2. **Monocromia:** peso del dominante $\geq 90\%$.

Metrica diagnostica (indipendente dalla configurazione). La **contraddizione** misura, su ciascuna frase del corpus, se il top-1 FEEL-IT (mappato su colore) e il top-1 lessicale coincidono. Poiché confronta sempre i due canali sorgente, il suo tasso sul corpus (59,1%) è *identico* in tutte le righe dell'ablation: non indica la qualità della configurazione finale, ma la frequenza di disaccordo intrinseco tra neurale e simbolico sul test set.

Configurazioni confrontate (ablation): solo FEEL-IT; solo lessico; ibrido 50/50 senza boost; ibrido completo v5; ibrido senza smoothing top- k . Riproducibilità: `python scripts/ablation_study.py`.

8.3 Risultati quantitativi dell'ablation study

Tabella 6: Risultati ablation study: studio esplorativo preliminare ($n=44$)

Configurazione	Acc. (%)	Monocromia (%)	Acc. minimal
Solo FEEL-IT	31,8	97,7	18,8%
Solo lessico	86,4	88,6	100,0%
Ibrido 50/50 (no boost)	65,9	34,1	81,3%
Ibrido completo (v5)	81,8	34,1	100,0%
Ibrido senza smoothing	81,8	34,1	100,0%

Tabella 7: Metrica diagnostica: tasso di contraddizione neurale-lessicale sul corpus ($n=44$)

Descrizione	Valore
Fraasi con disaccordo top-1 neurale vs lessicale	26 / 44 (59,1%)

Nota: il tasso è *costante* tra le configurazioni dell’ablation, perché la metrica confronta i canali sorgente (FEEL-IT mappato su colore vs top-1 lessicale), non l’output del blend finale.

Tabella 8: Accuratezza per lunghezza del testo: Solo FEEL-IT vs Ibrido completo

Lunghezza	n	Solo FEEL-IT	Ibrido v5
Minimal (1-2 token)	16	18,8%	100,0%
Breve (3-6 token)	16	43,8%	87,5%
Lungo (>6 token)	12	33,3%	50,0%
Totale	44	31,8%	81,8%

Tabella 9: Accuratezza per categoria semantica (Ibrido completo v5)

Categoria	Descrizione	Acc. (%)
short	Etichette affettive isolate (<i>gioia, rabbia...</i>)	100,0
medium	Fraasi 2-4 parole (<i>sono felice...</i>)	86,7
long	Fraasi estese con contesto	50,0
negation	Negazione esplicita ($n=2$)*	100,0
implicit	Emozione implicita (lemma indiretto nel lessico)	100,0
literal	Riferimento cromatico letterale	100,0

*I due casi di negazione nel corpus (*non sono felice, senza gioia nel cuore*) sono classificati correttamente con la configurazione attuale, ma il modulo non inverte semanticamente il colore: attenua solo il peso lessicale (0,25) e può comunque lasciare attivo il lemma negato (es. “felice” → Giallo). V. Sezione 8.6.

Rispetto a FEEL-IT isolato, l’ibrido completo (Tab. 6) recupera **+81,2 punti percentuali** su input minimali (1-2 token: 18,8% → 100%) e raggiunge il 81,8% di accuratezza globale sul corpus. Il **solo lessico** ottiene l’accuratezza più alta (86,4%): risultato *atteso*, poiché molte fraasi contengono keyword esplicite allineate al gold. L’ibrido non è progettato per massimizzare l’accuratezza lessicale su questo corpus, ma come **compromesso più robusto**: corregge gli errori del modello su etichette isolate (dove FEEL-IT crolla al 31,8%) e mantiene il contributo contestuale del canale neurale su testi senza lemma diretto, obiettivo centrale di un sistema interattivo in tempo reale.

8.4 Bias verso la classe Paura

Su etichette affettive isolate ($n=12$), FEEL-IT colloca il **75,0%** dei casi nella classe *paura* e produce Violetto come colore dominante errato nel **66,7%** dei casi (accuratezza cromatica 8,3%). Con il boost lessicale al 72%, l’accuratezza cromatica sul sottoinsieme sale al **100%** e le false attivazioni di Violetto su input non timorosi si **azzerano** (Tab. 10). Il classificatore neurale resta internamente orientato verso *fear*, ma il canale lessicale corregge l’output visivo-sonoro nel corpus analizzato.

Tabella 10: Bias verso *Paura* su etichette isolate ($n = 12$)

Configurazione	Acc. cromatica	FEEL-IT $\rightarrow$ fear	False Violetto
Solo FEEL-IT	8,3%	75,0%	66,7%
Ibrido v5	100,0%	75,0%*	0,0%

*Il logits neurale non cambia; la metrica rilevante per l'output è il false Violetto sul blend finale.

8.5 Analisi qualitativa: frasi corte vs lunghe

Tabella 11: Regime di pesatura in funzione della lunghezza

Lunghezza	n token	Peso lessico β	Comportamento atteso
Minimal	1-2	0,72 (se $\ell^* \geq 0,4$)	Lessico domina su errori FEEL-IT
Breve	3-6	0,72	Stesso regime; più contesto sintattico
Lunga	> 6	0,50	Modello e lessico equilibrati
Senza match lessicale	qualsiasi	N/A	Solo canale neurale (nessuna fusione ℓ)

Tabella 12: Confronto lessico esplicito vs costruzione predicativa (esempi misurati con FEEL-IT reale)

Testo	FEEL-IT top-1	Lessico	Blend dominante
<i>gioia</i>	fear (99,6%)	Giallo 100%	Giallo 64,9% + Violetto 35,1%
<i>sono felice</i>	joy (99,9%)	Giallo 100%	Giallo 100%
<i>rabbia</i>	fear (99,6%)	Vermiglio 100%	Vermiglio 64,9% + Violetto 35,1%
<i>sono arrabbiato</i>	anger (99,9%)	Vermiglio 100%	Vermiglio 100%
<i>amo questa giornata meravigliosa</i>	joy (99,9%)	Rosa 100%	Rosa 64,9% + Giallo 35,1%

Su *gioia* isolato, FEEL-IT classifica erroneamente *fear*; con boost lessicale al 72% il **dominante** diventa Giallo (accuratezza cromatica corretta), ma il residuo neurale mantiene Violetto come componente secondaria nel blend (64,9% + 35,1% dopo smoothing). Sui predicati espliciti (*sono felice*, *sono arrabbiato*) modello e lessico concordano al 100%. Su *amo...*, l'ibrido privilegia Rosa (amore), estendendo le 4 classi FEEL-IT.

Tabella 13: Parole attivate e canale dominante

Espressione	Match lessico	Colore lessicale	Canale che decide
<i>gioia</i>	<i>gioia</i> $\rightarrow$ gelb	Giallo	Ibrido (lessico corregge fear)
<i>sono felice</i>	<i>felice</i> $\rightarrow$ gelb	Giallo	Entrambi (accordo)
<i>meraviglioso</i>	<i>meraviglioso</i> $\rightarrow$ gelb	Giallo	Lessico + neurale (concordanza)
<i>amo</i>	<i>amo</i> $\rightarrow$ rosa	Rosa	Lessico estende oltre FEEL-IT

FEEL-IT opera sull'embedding dell'intera frase; il lessico conta occorrenze esplicite. L'ibrido $\alpha\mathbf{m} + \beta\ell$ equilibra i due paradigmi.

8.6 Limiti noti

Tabella 14: Errori residui dell’ibrido v5 (8 su 44): pattern sistematici

Testo (estratto)	Gold	Predetto
<i>mi fido di te / Mi fido ciecamente...</i>	Azzurro	Giallo
<i>amo questa giornata meravigliosa...</i>	Rosa	Giallo
<i>Il tramonto arancione...</i>	Arancione	Giallo
<i>La natura verde mi riempie...</i>	Verde	Giallo
<i>verde speranza natura</i>	Verde	Giallo
<i>meraviglia mistica...</i>	Porpora	Cremisi
<i>Violetto crepuscolo...</i>	Porpora	Violetto

Permangono limiti strutturali:

- **Negazione:** peso attenuato (0,25) senza inversione semantica; con un solo match attivo la normalizzazione può comunque produrre $\ell_c=1$ su quel colore (es. “non sono felice” può ancora attivare “felice” $\rightarrow$ Giallo). I due casi di negazione nel corpus sono gestiti correttamente, ma non generalizzano il problema;
- **Lemma cromatico:** il lessico non include tutti i nomi di colore (es. *verde* assente; *speranza* mappa al Giallo);
- **Substring:** sovrapposizioni lessicali (es. *rabbi* in *rabbia*);
- **Dominio FEEL-IT:** addestrato su tweet, non su testo letterario;
- **Granularità cromatica:** conflitti tra colori affini (Giallo/Arancione, Porpora/Violetto);
- **Corpus e metodologia:** 44 stimoli di controllo redatti dagli autori, senza annotazione inter-rater; calibrazione e valutazione sullo stesso insieme (rischio *overfitting*).

I risultati ottenuti devono essere interpretati come **preliminari**: il corpus è ridotto e costruito dagli autori; alcuni iperparametri sono stati calibrati sugli stessi esempi usati per la valutazione. Sarà necessario, in sviluppi futuri, validare il sistema su un dataset indipendente con annotazioni prodotte da più valutatori.

9 Discussione e Conclusioni

Gli approcci puramente generativi basati su Large Language Models possono risultare meno adatti quando si richiedono determinismo, bassa latenza e tracciabilità esplicita in media continui in tempo reale.

I risultati dello studio esplorativo (Sez. 8) suggeriscono che, *sul corpus di controllo considerato*, FEEL-IT da solo raggiunge il 31,8% di accuratezza cromatica, mentre l’architettura v5 sale all’81,8%, con recupero totale su etichette isolate e azzeramento delle false attivazioni di Violetto da bias *fear*. Il solo lessico supera l’ibrido in accuratezza (86,4%), confermando l’importanza delle keyword esplicite; l’ibrido resta preferibile quando si richiede integrazione del contesto neurale. Il motore lessicale amplia lo spettro da 4 emozioni FEEL-IT a 11 colori goethiani. L’implementazione open source [10] (Sez. 5) consente di ispezionare ogni stadio della pipeline e riprodurre le metriche riportate.

Sviluppi futuri: (1) corpus più ampio con test set indipendente e doppia annotazione; (2) calibrazione degli iperparametri su insieme di sviluppo separato; (3) Word Sense Disambiguation e gestione strutturata della negazione nel lessico; (4) benchmark sistematico di latenza e verifica della completezza IG; (5) integrazione multimodale e studio utenti sulla percezione estetica.

Riferimenti bibliografici

- [1] Bianchi, F., Nozza, D., & Hovy, D. (2021). FEEL-IT: Emotion and Sentiment Classification for the Italian Language. *Proceedings of the Eleventh Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis* (pp. 76-83). Association for Computational Linguistics.
- [2] von Goethe, J. W. (1810). *Zur Farbenlehre (Theory of Colours)*. Tübingen: J. G. Cotta. (Trad. Inglese: C. L. Eastlake, 1840).
- [3] Russell, J. A. (1980). A circumplex model of affect. *Journal of Personality and Social Psychology*, 39(6), 1161-1178.
- [4] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, 30.
- [5] Sundararajan, M., Taly, A., & Yan, Q. (2017). Axiomatic attribution for deep networks. *Proceedings of the 34th International Conference on Machine Learning (ICML)*.
- [6] Palmer, S. E., & Schloss, K. B. (2010). An ecological valence theory of human color preference. *Proceedings of the National Academy of Sciences*, 107(19), 8877-8882.
- [7] Marks, L. E. (1974). On associations of light and sound: The mediation of brightness, pitch, and loudness. *American Journal of Psychology*, 87(1-2), 173-188.
- [8] Ferguson, S., & Brewster, S. (2017). Investigating the psychophysiological effects of auditory sharpness and roughness. *Interacting with Computers*, 29(4), 504-521.
- [9] Ramírez, S. (2018). *FastAPI*. [Online]. Disponibile su: <https://fastapi.tiangolo.com/>
- [10] Pecilli, A., & Cerretani, M. (2025). *Aisthesis v5*: repository sorgente. [Online]. Disponibile su: <https://github.com/Alessio-Pecilli/Aisthesis>